

UNIVERZITA KOMENSKÉHO V BRATISLAVE
FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY

TRIEDENIE PLASTOVÉHO ODPADU POMOCOU UMELEJ
INTELIGENCIE
BAKALÁRSKA PRÁCA

2026

JURAJ ŠUMNÝ

UNIVERZITA KOMENSKÉHO V BRATISLAVE
FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY

TRIEDENIE PLASTOVÉHO ODPADU POMOCOU UMELEJ
INTELIGENCIE
BAKALÁRSKA PRÁCA

Študijný program: Aplikovaná informatika
Študijný odbor: Informatika
Školiace pracovisko: Katedra informatiky
Školiteľ: doc. RNDr. Zuzana Černeková, PhD.

Bratislava, 2026
Juraj Šumný



Univerzita Komenského v Bratislave
Fakulta matematiky, fyziky a informatiky

ZADANIE ZÁVEREČNEJ PRÁCE

Meno a priezvisko študenta: Juraj Šumný
Študijný program: aplikovaná informatika (Jednoodborové štúdium, bakalársky I. st., denná forma)
Študijný odbor: informatika
Typ záverečnej práce: bakalárska
Jazyk záverečnej práce: slovenský
Sekundárny jazyk: anglický

Názov: Triedenie plastového odpadu pomocou umelej inteligencie
Sorting plastic waste with AI

Anotácia: V súčasnosti sa intenzívne rozvíjajú technológie na triedenie odpadu s dôrazom na využitie umelej inteligencie a robotiky, ktoré umožňujú presnejšie a efektívnejšie spracovanie plastových materiálov. Táto diplomová práca sa zaoberá návrhom inteligentného triediaceho systému, ktorý využíva hyperspektrálnu analýzu na detekciu a klasifikáciu rôznych plastových komodít, čím prispieva k automatizácii a zvyšovaniu ekonomickej efektívnosti recyklačných procesov.

Cieľ: Cieľom práce je preskúmať metódy dostupné v odbornej literatúre využívané pri triedení plastového odpadu. Analyzovať dostupné data a pripraviť dataset na spracovanie. Navrhnuť a implementovať metódu s dôrazom na identifikáciu rôznych plastových materiálov. Vyhodnotiť efektívnosť navrhnutého systému pri separácii plastového odpadu.

Vedúci: doc. RNDr. Zuzana Černeková, PhD.
Katedra: FMFI.KAI - Katedra aplikovanej informatiky
Vedúci katedry: doc. RNDr. Tatiana Jajcayová, PhD.
Dátum zadania: 19.02.2025

Dátum schválenia: 18.03.2025
doc. RNDr. Damas Gruska, PhD.
garant študijného programu

študent

vedúci práce

Čestné vyhlásenie: Čestne vyhlasujem, že celú bakalársku prácu na tému „Triedenie plastového odpadu pomocou umelej inteligencie“, vrátane všetkých jej príloh a obrázkov, som vypracoval samostatne, a to s použitím literatúry uvedenej v priloženom zozname. Pri príprave tejto práce boli tiež použité nástroje umelej inteligencie NotebookLM a Gemini 3 Flash za účelom kontroly, vysvetlenia odborných textov, vytvorenia štruktúry textu a pomoci pri programovaní. Nástroje umelej inteligencie som použil v súlade s príslušnými právnymi predpismi, akademickými právami a slobodami, etickými a morálnymi zásadami za súčasného dodržania akademickej integrity. Som si vedomý, že plne zodpovedám za správnosť výsledného textu.

PodĎakovanie: Chcel by som sa poďakovať svojej školiteľke doc. RNDr. Zuzane Černekovej, PhD., za odborné vedenie, cenné podnety k bakalárskej práci a ochotu poradiť vždy, keď to bolo potrebné. Ďakujem aj za pomoc pri zbere dát, ktorého sa vždy zúčastnila. Taktiež chcem poďakovať firme EDIKO SK, za poskytnutie hyperspektrálnych dát, bez ktorých by táto bakalárska práca nebola možná.

Abstrakt

(Budem robiť až na koniec)

Abstract

(Váš anglický abstrakt)

Obsah

Úvod	1
1 Súčasný stav problematiky	2
1.1 Kategorizácia a spracovanie plastového odpadu	2
1.1.1 Spôsoby spracovania plastového odpadu	2
1.2 Hyperspektrálny obraz (HSI)	2
1.3 Osvetľovacie systémy	4
1.4 Rádiometrická kalibrácia	5
1.4.1 Prevod na odrazivosť	6
1.5 Vyhľadzovanie signálu pomocou Savitzky-Golay filtra	6
1.6 Transformácia pomocou prvej derivácie	7
1.7 PLS-DA	8
1.7.1 Algoritmus	8
1.7.2 Identifikácia významných vlnových dĺžok	9
1.8 Logistická regresia	10
1.8.1 Matematický model a algoritmus výpočtu	10
1.9 Extreme Gradient Boosted Decision Trees	11
1.10 Metriky hodnotenia úspešnosti klasifikácie	12
2 Návrh a implementácia klasifikačného softvéru	13
2.1 Získavanie a predspracovanie dát	13
2.1.1 Štruktúra vstupných dát	14
2.1.2 Rádiometrická kalibrácia	14
2.1.3 Ukladanie dát	14
2.1.4 Použité datasety	15
2.2 Návrh a trénovanie klasifikačného modelu	15
2.3 Logistická regresia	17
2.3.1 Implementácia triedy PlasticClassifierLogistic	17
2.4 Extreme Gradient Boosted Decision Trees	18
2.4.1 Implementácia triedy PlasticClassifierXGB	18
2.5 Implementácia validačného a porovnávacieho skriptu	20
2.5.1 Meranie výkonnostných metrík a simulácia push-broom snímania . . .	20

3	Interpretácia výsledkov a analýza modelu	22
3.1	Analýza separability dát pomocou t-SNE	22
3.2	Výsledky klasifikačnej metódy PLS-DA	24
3.2.1	Načítanie a predspracovanie dát	24
3.2.2	Postprocessing	24
3.2.3	Vizualizácia výsledkov	25
3.2.4	Analýza latentného priestoru a separácie tried pomocou PLS-DA . . .	27
3.3	Klasifikácia pomocou logistickej regresie a priestorová filtrácia	28
3.3.1	Analýza spektrálnej významnosti logistickej regresie	30
3.3.2	Optimalizácia klasifikácie zúžením spektrálneho rozsahu	30
3.3.3	Analýza spektrálnych charakteristík	31
3.4	Vyhodnotenie výsledkov s redukovaným spektrom	32
3.4.1	Klasifikácia pomocou Extreme Gradient Boosted Decision Trees	33
3.5	Analýza výpočtovej náročnosti klasifikačných modelov	34
3.5.1	Náročnosť predspracovania dát Savitzky-Golay filtra	34
3.5.2	Teoretická zložitosť predikčných modelov	34
3.5.3	Vyhodnotenie efektivity	35
3.6	Celkové vyhodnotenie a porovnanie modelov	35
3.6.1	Detailné výsledky metódy PLS-DA	36
3.6.2	Detailné výsledky Logistickej regresie	36
3.6.3	Detailné výsledky metódy XGBDT	36
3.6.4	Analýza úspešnosti klasifikácie a problematických materiálov	36
	Záver	38
	Literatúra	39
	Príloha A	41
	Príloha B	42

Zoznam obrázkov

1.1	Ilustrácia hyperspektrálneho snímania	3
1.2	Hyperspektrálny obrázok [2]	4
1.3	Osvetlenie dopravníkového pásu v praxi.	5
1.4	Ukážka vyhladenia zašumeného signálu pomocou Savitzky-Golay filtra [3]	7
1.5	[5]Architektúra algoritmu Gradient Boosted Decision Trees.	11
2.1	Grafické rozhranie nástroja	13
3.1	2D Vizualizácia hyperspektrálnych dát pomocou t-SNE	23
3.2	Porovnanie klasifikácie pomocou predprogramu od Specim a našou klasifikáciou.	26
3.3	PLS-DA Score Plot: Vizualizácia separácie jednotlivých materiálov v priestore latentných premenných.	27
3.4	Porovnanie pôvodnej scény a výsledku klasifikácie logistickou regresiou.	29
3.5	Suma absolútnych hodnôt koeficientov logistickej regresie identifikujúca kritické vlnové dĺžky.	30
3.6	Priemerná odrazivosť polymérov.	31
3.7	Klasifikácia PS pri zachovaní všetkých spektrálnych kanálov.	32
3.8	Klasifikácia PS pri redukcii na kanály 40 – 80.	32
3.9	Klasifikácia PS pri orezaní na kanály 100 – 180.	33

Zoznam tabuliek

3.1	Matica zámien pre finálny klasifikačný model.	26
3.2	Matica zámien pre model logistickej regresie.	29
3.3	Matica zámien pre model XGBDT (XGBoost)	33
3.4	Finálne výsledky a časová náročnosť klasifikácie jedného riadka obrazu (640 px)	35
3.5	Metriky metódy PLS-DA podľa tried (Full spectrum)	36
3.6	Metriky Logistickej regresie podľa tried (Full spectrum)	36
3.7	Metriky metódy XGBDT podľa tried (Full spectrum)	37

Úvod

Predložená bakalárska práca sa zameriava na spôsob automatizácie triedenia plastového odpadu s využitím metód umelej inteligencie. Výskum prebieha v úzkej spolupráci so spoločnosťou edico sk, ktorá pre potreby analýzy poskytla vlastné hyperspektrálne dáta. Snímanie a zber dát sa uskutočňuje za pomoci hyperspektrálnej kamery Specim FX17. Toto zariadenie pracuje v blízkej infračervenej oblasti NIR v rozsahu vlnových dĺžok 935 nm až 1720 nm. Na rozdiel od bežných kamier sníma scény v 224 spektrálnych kanáloch, čo umožňuje zachytiť detailné chemické vlastnosti materiálov, ktoré sú voľným okom neviditeľné. Hlavnou ambíciou výskumu je transformácia týchto surových dát na klasifikačné modely. Primárnym cieľom je dosiahnutie maximálnej presnosti pri rozpoznávaní jednotlivých polymérov, čím sa minimalizuje chybovosť pri triedení. Súčasne je však nevyhnutné klásť dôraz na výpočtovú efektivitu a urýchlenie procesu spracovania. V priemyselnej praxi musia metódy reagovať v reálnom čase, aby dokázali správne identifikovať plastový odpad pohybujúci sa na rýchlych dopravníkových pásoch a následne robotickou rukou bude separovaný. Dôležitým ekonomickým aspektom práce je aj hľadanie metód na redukcii počtu potrebných kanálov. Zníženie objemu spracovávaných dát vedie k nižším nárokom na hardvér a výpočtovú silu, čo v konečnom dôsledku znižuje náklady na nasadenie týchto inteligentných systémov v reálnych triediacich linkách a zníži potrebný čas na klasifikáciu.

Kapitola 1

Súčasný stav problematiky

1.1 Kategorizácia a spracovanie plastového odpadu

Súčasná globálna produkcia plastov predstavuje kritickú environmentálnu výzvu, primárne kvôli ich chemickej stabilite a dlhej dobe rozkladu v prírode. Efektívny manažment tohto odpadu vyžaduje presnú identifikáciu a separáciu podľa chemického zloženia, nakoľko miešanie rôznych typov polymérov pri recyklácii vedie k degradácii výsledného materiálu. V praxi sa plasty klasifikujú do siedmich kategórií, ktoré definujú ich vlastnosti a možnosti ďalšieho využitia.

[11] Najbežnejšími zástupcami sú termoplasty ako **PET**, využívaný pre svoju čírosť a pevnosť v nápojovom priemysle, a **HDPE**, ktorý vďaka svojej chemickej odolnosti dominuje v segmente čistiacich prostriedkov a kozmetiky.

Konštrukčné a obalové materiály dopĺňajú **PVC**, typický pre stavebné prvky, a **LDPE**, ktorý tvorí väčšinu flexibilných fólií a sáčkov. Špecifickú skupinu tvoria **PP**, odolávajúci vysokým teplotám pri balení potravín, a **PS**, známy svojou nízkou hmotnosťou a krehkosťou.[11]

1.1.1 Spôsoby spracovania plastového odpadu

[13] Proces nakladania s plastovým odpadom sa po jeho vytriedení delí na tri základné technologické prístupy, ktorých voľba závisí od čistoty a typu suroviny.


Mechanická recyklácia predstavuje najrozšírenejšiu metódu, kde sa odpad čistí, drví na vločky a následne taví na granulát. Tento proces je ekonomicky najefektívnejší, avšak naráža na limity v podobe postupnej degradácie polymérnych reťazcov pri opakovanej tepelnej záťaži.

Chemická recyklácia ponúka riešenie pre znečistené alebo zmiešané plasty, ktoré nie sú vhodné pre mechanické spracovanie. Proces spočíva v rozklade plastu na základné monomerné jednotky alebo chemické suroviny. Hoci je metóda energeticky náročnejšia, umožňuje produkciu plastov s kvalitou identickou s novovytvorenými materiálmi.[13]

1.2 Hyperspektrálny obraz (HSI)

[16] Hyperspektrálne zobrazovanie predstavuje technológiu, ktorá spája klasickú fotografiu so spektroskopiou. Na rozdiel od bežného fotoaparátu, ktorý zachytí len to, čo vidí ľudské oko,

HSI zaznamenáva dáta v širokom rozsahu elektromagnetického spektra. Výsledkom je detailná informácia o spektre pre každý jeden pixel v obraze.



Obr. 1.1: Ilustrácia hyperspektrálneho snímania

Rozdiel medzi HSI a RGB kamerou

Bežné RGB kamery pracujú len s tromi širokými pásmami viditeľného svetla – červenou, zelenou a modrou, zatiaľ čo hyperspektrálne senzory poskytujú oveľa podrobnejšie dáta. Na rozdiel od troch kanálov RGB obsahuje HSI stovky kanálov a ich rozsah presahuje viditeľné spektrum (380–750 nm), pričom často pokrýva pásmo od 250 nm (ultrafialové) až po 15 000 nm pre dlhovlnné infračervené žiarenie. Táto miera detailnosti odhaľuje informácie neviditeľné pre ľudské oko či štandardné snímače, čím umožňuje priamo určovať chemické vlastnosti objektov.


Spektrálny podpis a identifikácia materiálov

Základným princípom identifikácie je fakt, že každý materiál interaguje so svetlom inak, pričom časť vlnových dĺžok pohltí a časť odrazí v závislosti od svojho chemického zloženia. Tento proces vytvára spektrálny podpis, čo je jedinečný profil odrazivosti fungujúci analogicky k ľudskému odtlačku prsta. V praxi to umožňuje rozlíšiť materiály, ktoré sú vizuálne nerozoznateľné, ako napríklad biely plast typu PET a PVC. Ich odlišná chemická štruktúra sa v HSI dátach jasne prejaví, čím získavame informácie o zložení, ktoré sú bežným pohľadom nezistiteľné.

Dátová štruktúra (Hypercube)

Výstupom z hyperspektrálneho snímania nie je bežný plochý obrázok, ale hyperspektrálna dátová kocka, ktorá v sebe integruje priestorové a spektrálne informácie. Táto štruktúra je definovaná tromi dimenziami, kde priestorové rozmery (x, y) určujú presnú polohu pixelu v obraze, zatiaľ čo spektrálny rozmer (z) reprezentuje konkrétnu vlnovú dĺžku prislúchajúcu danému bodu.[16]

Vďaka tejto štruktúre môžeme pre každý pixel v scéne extrahovať spojitú spektrálnu krivku, ktorú následne používame ako vstup pre algoritmy strojového učenia. To je kľúčové pre presné triedenie odpadu, kde potrebujeme odlíšiť materiály s podobnými vizuálnymi cha-



Obr. 1.2: Hyperspektrálny obrázok [2]

rakteristikami, ale iným zložením.

1.3 Osvetľovacie systémy

Kvalita osvetlenia je pri hyperspektrálnom snímaní kľúčová pre získanie správnych dát. V našom prípade sa využíva halogénové osvetlenie spolu s prirodzeným slnečným svetlom.

[15]Halogény sú pravdepodobne najbežnejším a najlacnejším zdrojom svetla pre hyperspektrálne zobrazovanie. Spektrálne zloženie závisí od teploty zdroja, pričom teplejšie halogény obsahujú viac modrého signálu ako chladnejšie, ale majú menej infračerveného žiarenia.

Medzi hlavné výhody halogénov patrí nízka cena, kontinuálne spektrum v rozsahu 400 až 2500 nm a dobrá emisia v infračervenej oblasti. Nevýhodou je ich krátka životnosť, produkcia tepla a potreba optiky, ako sú eliptické reflektory, na zaoštrovanie svetla. Halogény majú slabú emisiu v modrej oblasti a vysokú intenzitu okolo 1000 nm, čo nie je optimálne pre meranie farieb.

V mnohých aplikáciách, kde je meranie farieb vyžadované, sa používajú halogény upravené filtermi. Tieto lampy majú reflektor, ktorý neodráža infračervené žiarenie vpred, ale necháva ho prejsť dozadu, čím sa znižuje tepelné zaťaženie povrchu. Takéto lampy sa však nemôžu používať pri NIR alebo SWIR meraniach. V priemyselnom prostredí je osvetlenie kľúčovou súčasťou triediacich liniek, kde sú zdroje svetla umiestnené priamo nad dopravníkovým pásom (Obr. 1.2).

Slnko samo o sebe poskytuje osvetlenie s kontinuálnym spektrom. Atmosféra obklopujúca Zem však obsahuje plyny s absorpčnými vlastnosťami, ktoré tvarujú osvetlenie dopadajúce na povrch planéty.

Slnečné svetlo je veľmi relevantné medzi 400 a 1000 nm, ale nad túto hranicu je pri korekcii spektier potrebné zapojiť atmosférické modely. Výhodou solárneho osvetlenia je, že je homogénne, má relatívne kontinuálne spektrum od 400 do 1000 nm a je zadarmo. Nevý-



Obr. 1.3: Osvetlenie dopravníkového pásu v praxi.

[1]

hody zahŕňajú dostupnosť iba počas dňa, vplyv mrakov na infračervenú emisiu a prítomnosť atmosférických absorpčných vrcholov.[15]

1.4 Rádiometrická kalibrácia

Surové dáta z kamery sú v podstate len namerané intenzity elektrického signálu v jednotlivých pixeloch senzora. Samy o sebe sú pre analýzu nepoužiteľné, pretože nezohľadňujú aktuálne osvetlenie scény ani vnútorný šum kamery. Bez kalibrácie by ten istý plast vyzeral pod rôznymi lampami úplne inak, čo by znemožnilo spoľahlivú klasifikáciu.

Čierna a biela referencia

Na odstránenie nežiaducich vplyvov a kalibráciu senzora sa využívajú dve referencie [12]. Prvým je čierna referencia, ktorá sa získava snímaním s úplne zatvorenou uzávierkou, čím sa zachytáva výhradne tepelný šum senzora a takzvaný baseline offset. Tento nameraný šum

sa následne odpočítava od každého pixelu v reálnom obraze, aby v dátach zostal len čistý signál odrazený od snímaného objektu. Na tento krok nadväzuje biela referencia, realizovaná snímaním kalibračnej čisto bielej doštičky, ktorá rovnomerne odráža takmer 100 % dopadajúceho svetla. Tento proces umožňuje eliminovať nerovnomernosti v osvetlení scény a zohľadniť rozdielnú citlivosť senzora na rôznych vlnových dĺžkach, čím sa definuje maximálna možná difúzna hodnota odrazivosti.

1.4.1 Prevod na odrazivosť

Spoločné použitie týchto dvoch referencií umožňuje konvertovať surové dáta na odrazivosť. Je to bezrozmerná hodnota v rozsahu 0 až 1 alebo 0 až 100 %, ktorá vyjadruje čistú vlastnosť materiálu nezávislú od okolitého prostredia. Hodnota však niekedy môže nadobudnúť aj hodnoty nad 100%, čo sa prejavuje hlavne pri existencii spekulárnej zložky osvetlenia.

Odrazivosť predstavuje fyzikálnu vlastnosť materiálu, ktorá vyjadruje pomer odrazeného žiarenia k dopadajúcemu žiareniu. Na jej výpočet z hyperspektrálnych dát je potrebné eliminovať vplyv senzora a osvetlenia.

Samotný výpočet spočíva v odčítaní tmavej referencie od surových dát a následnej normalizácii pomocou rozdielu medzi bielou a tmavou referenciou. Výsledkom je bezrozmerná veličina, ktorá umožňuje porovnávanie rôznych materiálov.

Tento postup je štandardne používaný v hyperspektrálnom zobrazovaní na získanie dát vhodných pre ďalšiu analýzu a klasifikáciu materiálov .


$$[9] \text{Odrazivosť} = \frac{\text{surové dáta} - \text{čierna referencia}}{\text{biela referencia} - \text{čierna referencia}} \quad (1.1)$$

1.5 Vyhladzovanie signálu pomocou Savitzky-Golay filtra

Hyperspektrálne dáta sú prirodzene zašumené v dôsledku citlivosti senzora alebo kolísania svetelného zdroja, čo vyžaduje aplikáciu metód na elimináciu šumu pri súčasnom zachovaní kľúčových spektrálnych črt. Metóda Savitzky-Golay smoothing [18] tento problém rieši princípom lokálneho prekladania polynómu. Algoritmus prechádza spektrum pomocou pohyblivého okna, v ktorom v každom kroku preloží body polynómom zvoleného stupňa. Pôvodná hodnota v strede okna je následne nahradená hodnotou z vypočítaného polynómu, čo efektívne redukuje šum bez výrazného skreslenia tvaru spektra.

Kľúčové parametre implementácie

Pri implementácii filtra je nevyhnutná precízna voľba dvoch parametrov: veľkosti okna (window length) a stupňa polynómu (polyorder). Veľkosť okna definuje počet susedných kanálov vstupujúcich do výpočtu, a je dôležité vybrať správnu veľkosť, aby nedošlo ku oversmoothingu, teda k nežiaducemu potlačeniu dôležitých spektrálnych vrcholov. Stupeň polynómu určuje komplexnosť prekladanej krivky, ktorá tiež keď sa vyberie zle, tak dochádza ku overfittingu, kedy filter začne kopírovať samotný šum namiesto toho, aby ho odfiltroval.



Obr. 1.4: Ukážka vyhladenia zašumeného signálu pomocou Savitzky-Golay filtra [3]

Kombinácia s deriváciou: Savitzky-Golay vyhladzovanie v softvéri kombinujeme s výpočtom prvej derivácie, pretože derivácie umožňujú vidieť a zvýrazniť malé zmeny v sklone spektra. Ich nevýhodou je vysoká náchylnosť na šum, a preto sa odporúča práve táto kombinácia. Aplikovaním SG filtra pred výpočtom derivácie získame čistú derivačnú krivku, ktorá je pre neurónovú sieť viac čitateľná.

1.6 Transformácia pomocou prvej derivácie

Transformácia pomocou prvej derivácie predstavuje metódu zameranú na analýzu zmien sklonu spektrálnej krivky. V kontexte hyperspektrálneho spracovania dát je tento prístup zásadný na zvýraznenie chemických príznakov materiálu.

Táto metóda efektívne eliminuje posun základnej línie a minimalizuje negatívne vplyvy spôsobené náhodným rozptylom svetla [18]. V praxi to umožňuje stabilizovať spektrum aj v prípadoch, kedy je vzorka plastu nerovnomerne osvetlená alebo disponuje nepravidelným povrchom. Keďže však táto technika zároveň zvýrazňuje vysokofrekvenčný spektrálny šum, je nevyhnutné jej následné použitie v kombinácii so Savitzky-Golay filtrom na dosiahnutie optimálnej kvality dát.

Vysoká efektivita tejto transformácie v predikčných modeloch je potvrdená vedeckými štúdiami, pričom napríklad pri spektroskopickej analýze kovov boli zaznamenané výsledky s koeficientom determinácie R^2 až na úrovni 0,98 [18]. Tento vedecký základ dopĺňa fakt, že voľba prvej derivácie pre účely tejto práce reflektuje priemyselné štandardy spoločnosti Specim, ktorá túto techniku nasadzuje priamo vo svojich riešeniach pre automatizovanú detekciu plastového odpadu [17]. Uvedený prístup predstavuje v praxi optimálny nástroj na presné rozlíšenie polymérov, ktoré vykazujú vzájomne blízke spektrálne charakteristiky.

Napriek uvedeným výhodám je hlavným obmedzením derivačných transformácií prirodzené zosilňovanie vysokofrekvenčného náhodného šumu. Ak by sme derivovali neošetrený signál, výsledok by bol pre klasifikačné algoritmy nepoužiteľný. V implementovanom riešení preto FD transformácia úzko nadväzuje na Savitzky-Golay smoothing. Táto kombinácia zabezpečuje potrebnú rovnováhu, kedy SG filter odstráni šum a prvá derivácia následne z čistého

signálu vytiahne dôležité spektrálne črty potrebné pre tréning modelu.

1.7 PLS-DA

Metóda Partial Least Squares Discriminant Analysis (PLS-DA) predstavuje kľúčový nástroj multivariačnej štatistickej analýzy, ktorý sa široko využíva pri klasifikácii vysokorozmerných chemometrických dát. V kontexte hyperspektrálneho spracovania slúži na redukciu dimenzionality spektrálnych dát a následnú identifikáciu tried materiálov s maximálnou možnou separáciou, čím efektívne rieši obmedzenia tradičných štatistických prístupov. Jej hlavná sila spočíva v spracovaní komplexných dát s vysokou dimenzionalitou a multikolinearitou [4]. Algoritmus projektuje pôvodné premenné do nového priestoru latentných komponentov, pričom napríklad pri analýze olív [4] dokážu prvé dva komponenty vysvetliť až 97 % celkového rozptylu dát. Tým sa zásadne zjednodušujú výpočty bez straty kritických informácií.

Okrem redukcie dát PLS-DA dosahuje vysokú klasifikačnú presnosť, nakoľko identifikuje homogénnejšie a lepšie oddelené triedy v porovnaní s algoritmami ako KNN alebo SVM. Výslednú kvalitu separácie možno exaktne overiť pomocou miery chybnéj klasifikácie (MIS) a upraveného Rand indexu (ARI). Na rozdiel od black-box modelov navyše tento prístup umožňuje vysokú mieru interpretovateľnosti. Analýza váh a faktorového zaťaženia (weights and loadings) dovoľuje presne identifikovať konkrétne vlnové dĺžky, ktoré nesú najväčšiu váhu pri odlíšení konkrétnych materiálov.

1.7.1 Algoritmus

[4] Metóda PLS-DA je upravená verzia regresie čiastočných najmenších štvorcov (PLS-R), ktorá sa používa v prípadoch, keď je výstupná premenná kategorizovaná. Slúži na zníženie počtu premenných v dátach a následne na ich zaradenie do jednotlivých tried. Na rozdiel od metódy PCA, ktorá hľadá nadrovinu s maximálnym rozptylom, PLS-DA vytvára lineárny regresný model projektovaním predpovedaných premenných (X) a pozorovaných premenných (Y) do nového priestoru [4]. Tento proces je založený na rozklade matíc: [6] Matrica dát X (vlnové dĺžky) sa rozkladá na ortogonálne skóre (T), maticu záťaží (P) a maticu chýb (E):

$$X = TP^T + E$$

Vektor odozvy Y (kategórie) sa rozkladá na skóre (T), záťaž (Q) a chyby (F):

$$Y = TQ^T + F$$

Vlastný výpočet prebieha v iteratívnych krokoch pre vopred stanovený počet komponentov (P):

1. **Inicializácia:** Nastavia sa počiatočné rezíduá E_0 a F_0 .

$$E_0 = X, \quad F_0 = Y \tag{1.2}$$

2. **Výpočet váh:** Vypočíta sa vektor váh W_p .

$$W_p = E_0^T F_0 \quad (1.3)$$

3. **Výpočet skóre:** Vypočíta sa a normalizuje vektor skóre T_p .

$$T_p = E_0 W_p (W_p^T E_0^T E_0 W_p)^{-1/2} \quad (1.4)$$

4. **Výpočet záťaží (loadings):** Určia sa vektory záťaží pre X (P_p) a pre Y (Q_p).

$$P_p = E_0^T T_p, \quad Q_p = F_0^T T_p \quad (1.5)$$

5. **Aktualizácia rezíduí:** Z rezíduí sa odstráni informácia vysvetlená aktuálnym komponentom.

$$E_0 = E_0 - T_p P_p^T, \quad F_0 = F_0 - T_p Q_p^T \quad (1.6)$$

Po odhadnutí matíc váh, skóre a záťaží sa vypočíta vektor regresných koeficientov ($\hat{B}$). Hodnota neznámej vzorky ($\hat{Y}$) sa následne predpovedá ako súčin jej nameraných hodnôt (X) a týchto koeficientov: $\hat{Y} = X\hat{B}$.

Tento postup efektívne identifikuje latentné skóre, ktoré vysvetľujú najväčší možný podiel celkového rozptylu dát. V praxi často postačujú prvé dva alebo tri komponenty na vysvetlenie drvivej väčšiny informácií (podľa zdroja [4] až 97 %). Metóda zároveň poskytuje hlboký vhľad do príčin diskriminácie medzi triedami, pretože pomocou analýzy záťaží (P) je možné presne identifikovať konkrétne vlnové dĺžky v spektre s najväčším príspevkom k odlíšaniu skupín. V porovnaní s inými metódami, ako sú KNN alebo SVM, je PLS-DA mimoriadne vhodná pre dáta s vysokou multikolinearitou a v situáciách, kde počet premenných výrazne prevyšuje počet pozorovaní.

1.7.2 Identifikácia významných vlnových dĺžok

PLS-DA identifikuje kľúčové vlnové dĺžky prostredníctvom dekompozície dátovej matice na ortogonálne skóre a záťaž. Celý mechanizmus analýzy diskriminácie medzi triedami začína výpočtom vektora váh W , ktorý určuje smer v priestore vlnových dĺžok s najväčšou kovarianciou voči cieľovej kategórii. Tieto váhy slúžia na generovanie skóre reprezentujúceho vzorky v redukovanom priestore, na čo nadväzujú záťaž P . Tie vyjadrujú konkrétny príspevok každej pôvodnej vlnovej dĺžky k jednotlivým latentným komponentom a definujú vzťah medzi pôvodnými údajmi a novovytvorenými komponentmi. Ak vlnová dĺžka vykazuje vysokú absolútnu hodnotu záťaž, považuje sa za kriticky dôležitú pre definovanie daného komponentu.

Významnosť jednotlivých premenných sa následne určuje vizualizáciou distribúcie záťaží pozdĺž celého meraného spektra, napríklad v rozsahu 1100–2300 nm. Týmto spôsobom je možné identifikovať konkrétne spektroskopické vrcholy, ktoré majú najvyšší pozitívny alebo negatívny príspevok k separácii tried, čím sa prepája štatistická významnosť s reálnymi chemickými vlastnosťami materiálov. Praktickým príkladom je analýza olív [4], kde vlnové dĺžky v rozsahu 1100 až 1500 nm vykazovali vysoký negatívny príspevok k prvým dvom komponentom, zatiaľ čo rozsah 1900 až 2300 nm prispieval k prvému a tretiemu komponentu pozitívne.

Vďaka kombinácii týchto parametrov nefunguje PLS-DA ako uzavretý model, ale poskytuje priamu zrozumiteľnosť častí spektra, ktoré sú zodpovedné za úspešnú klasifikáciu.

1.8 Logistická regresia

[10]Logistická regresia predstavuje štatistickú metódu určenú na získanie pomeru šancí v situáciách, kedy na výsledný stav vplyva viacero vysvetľujúcich premenných súčasne. Hoci je jej postup metodologicky blízky viacnásobnej lineárnej regresii, zásadný rozdiel spočíva v binomickom charaktere závislej premennej, typicky reprezentovanej binárnymi stavmi. Hlavnou úlohou tejto metódy je komplexná analýza asociácií všetkých sledovaných premenných naraz, čím sa efektívne predchádza skresľujúcim účinkom, ktoré by mohli nastať pri izolovanom skúmaní faktorov.

Významnou prednosťou logistickej regresie je schopnosť priamo interpretovať spojené vysvetľujúce premenné bez potreby ich umelej kategorizácie, čo umožňuje presné modelovanie pravdepodobnosti konkrétneho výsledku na základe špecifických vlastností subjektu. Algoritmus navyše poskytuje exaktnú informáciu o individuálnom vplyve každej jednej premennej na celkový pomer šancí sledovanej udalosti. Tento prístup zaručuje vysokú mieru transparentnosti modelu, nakoľko je možné matematicky vyjadriť váhu, ktorou každý vstupný parameter prispieva k finálnej klasifikácii.

1.8.1 Matematický model a algoritmus výpočtu

Metóda definuje presný matematický postup pre modelovanie pravdepodobnosti udalosti (π). Keďže šanca je vyjadrená ako pomer, model v skutočnosti pracuje s logaritmom šance pomocou nasledovnej rovnice:

$$\log\left(\frac{\pi}{1-\pi}\right) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_m x_m$$


V tejto rovnici β_0 predstavuje priesečník pre referenčnú skupinu a β_i sú regresné koeficienty priradené k jednotlivým vysvetľujúcim premenným x_i .

Pre praktické zostavenie modelu sa využívajú dve stratégie. Prvou je úplný model, kde výpočet začína so všetkými premennými, ktoré sa následne po jednej odstraňujú. Druhou je prázdny model, ktorý začína len s priesečníkom a premenné sa postupne pridávajú. V našom kóde využívame prístup úplného modelu, avšak bez následného odstraňovania najmenej významných parametrov, všetky zvolené premenné sú v modeli ponechané.

Výsledné koeficienty β sa interpretujú cez ich exponenciálnu hodnotu ($\exp(\beta)$). Táto hodnota vyjadruje, koľkokrát sa zvýši šanca na výskyt sledovanej udalosti pri zmene kategórie alebo pri jednotkovom prírastku spojenej premennej.

1.9 Extreme Gradient Boosted Decision Trees

[5]Algoritmus XGBClassifier predstavuje efektívnu implementáciu rozhodovacích stromov s gradientným boostingom, ktorá je navrhnutá pre vysokú výpočtovú rýchlosť a predikčnú presnosť. Základným princípom fungovania tohto algoritmu je sekvenčná stavba súboru rozhodovacích stromov, kde sa jednotlivé modely pridávajú aditívne. Každý nasledujúci strom je trénovaný s primárnym cieľom korigovať reziduálne chyby, ktoré vznikli v predchádzajúcich iteráciách procesu učenia. Na minimalizáciu stratovej funkcie využíva model metódu gradientného zostupu, pričom kľúčovým vylepšením oproti štandardnému gradientnému boostingu je integrácia **L1 a L2 regularizácie**. Tieto mechanizmy kontrolujú zložitosť štruktúry stromov, čím výrazne prispievajú k presnosti modelu a eliminácii preučenia. Z hľadiska prak-



Obr. 1.5: [5]Architektúra algoritmu Gradient Boosted Decision Trees.

tického využitia ponúka XGBClassifier viacero výhod. Popri vysokej presnosti dosiahnutej kombinovaním slabých učiacich sa klasifikátorov do jedného silného celku, algoritmus exceluje aj v práci s nevyváženými datasetmi. Dokáže automaticky narábať s chýbajúcimi hodnotami a poskytuje širokú škálu nástrojov na kontrolu zovšeobecňovacej schopnosti, ako je napríklad technika **subsample** pre náhodný výber časti dát či **early stopping** pre predčasné ukončenie tréningu v momente, kedy validačné výsledky prestanú vykazovať zlepšenie. Celá implementácia je navrhnutá s dôrazom na maximálnu systémovú efektivitu, čo umožňuje paralelné výpočty a rýchlu inferenciu.

Napriek uvedeným pozitívam je nasadenie tohto algoritmu spojené s určitými obmedzeniami. Proces ladenia hyperparametrov, akými sú hĺbka stromov alebo miera učenia, je výpočtovo aj časovo náročný. Pri nesprávnej konfigurácii model stále vykazuje náchylnosť k overfittingu, kedy dosahuje vysokú úspešnosť na tréningových dátach, no stráca presnosť v reálnej praxi. Za významnú nevýhodu možno považovať nízku interpretovateľnosť výsledkov, keďže ide o black-box model, kde je určenie presnej príčinnej súvislosti medzi vstupnými premennými a finálnou identifikáciou materiálu náročné, čo môže byť problematické v aplikáciách vyžadujúcich vysvetliteľnosť rozhodnutí.

1.10 Metriky hodnotenia úspešnosti klasifikácie

Na objektívny odhad výkonnosti klasifikačných modelov a systémov spracovania informácií sa využívajú štandardizované ukazovatele odvodené z matice, zámien, ktorá kategorizuje výsledky na správne pozitívne (TP), falošne pozitívne (FP) a falošne negatívne (FN) [7]. Prvým kľúčovým indikátorom je **presnosť** (p), ktorá určuje, aká časť z objektov označených systémom za relevantné je v skutočnosti správna. Z hľadiska pravdepodobnostnej interpretácie ide o pravdepodobnosť, že objekt je relevantný pod podmienkou, že ho systém vrátil, čo vyjadruje vzťah:

$$p = \frac{TP}{TP + FP}$$

Vysoká hodnota presnosti indikuje, že model generuje len minimum nerelevantných výsledkov, čím sa zvyšuje spoľahlivosť detekcie. S touto metrikou úzko súvisí **úplnosť** (r), ktorá vyjadruje schopnosť systému nájsť a vrátiť všetky skutočne relevantné objekty z dostupnej množiny. V pravdepodobnostnom rámci ide o mieru úspešnosti identifikácie všetkých hľadaných prvkov, pričom výpočet prebieha podľa vzorca:

$$r = \frac{TP}{TP + FN}$$

Dosiahnutie vysokej úplnosti v praxi znamená, že systém vynechal len minimum dôležitých informácií. Keďže presnosť a úplnosť sú často v protiklade, na ich syntetické vyjadrenie sa využíva F1-skóre. Ide o harmonický priemer oboch metrík, ktorý sumarizuje celkovú výkonnosť systému do jedného ukazovateľa vhodného na objektívne porovnávanie rôznych klasifikačných metód:

$$F1 = \frac{2pr}{p + r} = \frac{2TP}{2TP + FN + FP}$$


Tento ukazovateľ poskytuje vyváženejší pohľad na kvalitu modelu než izolované sledovanie jednej metriky, nakoľko výrazne klesá v prípade, ak je presnosť alebo úplnosť na nízkej úrovni.

Kapitola 2

Návrh a implementácia klasifikačného softvéru

2.1 Získavanie a predspracovanie dát

Aby sme mohli plasty klasifikovať pomocou umelej inteligencie, potrebujeme najprv vytvoriť kvalitný dataset. Keďže hyperspektrálna kamera neprodukuje klasické obrázky, ale dátové kocky, vytvorili sme vlastný nástroj v jazyku Python. Tento nástroj umožňuje interaktívne vyberať pixely z nasnímaných scén a ukladať ich vyčistené spektrálne charakteristiky.



Obr. 2.1: Grafické rozhranie nástroja

Na ľavej strane je výber druhu plastu, v strede sa nachádza vizualizácia scény a na pravej strane sa nachádza výber množiny train alebo množiny val. V rámci GUI (Obr. 2.1) si používateľ zvolí konkrétny materiál a klikaním vytvára n-stranný polygón, v ktorom sa vy-

berý určitý počet náhodných pixelov, ktorý sa nastavý v kóde. Po vytvorení n-uholníka treba stlačiť tlačítko ULOŽIŤ, pre správne uloženie pixelov.

2.1.1 Štruktúra vstupných dát

Dáta získané z hyperspektrálnej kamery sú štandardne uložené vo formáte ENVI, ktorý pozostáva z dvojice komplementárnych súborov. Prvým je hlavičkový súbor s príponou .hdr, ktorý obsahuje kľúčové metadáta o snímke, predovšetkým jej priestorové rozmery a presný zoznam vlnových dĺžok prislúchajúcich jednotlivým spektrálnym pásmam. Na tento súbor nadväzujú surové binárne dáta s príponou .raw, ktoré uchovávajú namerané intenzity elektrického signálu z detektora. Tieto hodnoty v pôvodnom stave ešte nereprezentujú fyzikálnu odrazivosť materiálu, ale slúžia ako vstupný údaj pre následné kalibračné a analytické procesy. Na vizualizáciu v GUI používame PNG náhľad, čo je klasický RGB obrázok vygenerovaný zo spektrálnej kocky alebo z dopredu klasifikovaných dát.

2.1.2 Rádiometrická kalibrácia

Surové dáta sú ovplyvnené šumom senzora a intenzitou osvetlenia, preto každý pixel prepočítavame na odrazivosť pomocou čiernej a bielej referencie:

$$[9]\text{Odrazivost} = \frac{\text{surové dáta} - \text{čierna referencia}}{\text{biela referencia} - \text{čierna referencia}} \quad (2.1)$$

Algoritmus 2.1: Výpočet spektrálnej odrazivosti

```
current_dark = np.mean(envi.open(dark_p).load(), axis=(0, 1)).astype(
    float)
# Načítanie čiernej referencie a výpočet priemeru

current_white = np.mean(envi.open(white_p).load(), axis=(0, 1)).astype
    (float)
# Načítanie bielej referencie a výpočet priemeru

denom = current_white - current_dark
# Výpočet rozdielu medzi referenciami, ktorý tvorí menovateľ zlomku.

denom[denom == 0] = 1
# Ošetrovanie delenia nulou nahradením nulových hodnôt jednotkou.

refl = np.nan_to_num((raw_s - current_dark) / denom)
# Odčítanie šumu od signálu a vyčistenie
# neplatných číselných hodnôt pomocou nan_to_num.
```

2.1.3 Ukladanie dát

Program po každom kliknutí tlačítka ULOŽIŤ automaticky aktualizuje maticu datasetu vo formáte .npy. Tento binárny formát je optimálny pre rýchly zápis a efektívnu prácu s NumPy

poliami.

Algoritmus 2.2: ukladanie datasetu

```
data = np.vstack([data, spectrum])
# Vertikálne pridanie nového spektrálneho profilu ako riadku do matice
.

np.save(file_path, data)
# Uloženie celej matice do binárneho súboru .npy na disk.
```

Možnosť prepínať medzi režimami train a val v GUI zabezpečuje, že dáta sú už pri zbere rozdelené.

2.1.4 Použité datasety

Pre účely trénovania a následnej validácie klasifikačných modelov sme zbierali dáta z dvoch rôznych datasetov, ktoré boli poskytnuté firmou **EDIKO SK**.

Prvý z nich označujeme ako **uzatvorený dataset**. Táto množina obsahuje 5 000 pixelov vyhradených pre tréning a 20 000 vzoriek určených na validáciu. Špecifikom tohto datasetu je, že hoci sú validačné pixely odlišné od trénovacích, pochádzajú z identických fyzických kusov plastov, ktoré boli použité v trénovacom procese. Uzatvorený dataset slúži najmä na vizuálne porovnanie úspešnosti našej metódy s komerčným klasifikačným softvérom používaným v reálnej prevádzke.

Druhým súborom je **otvorený dataset**, ktorý je navrhnutý pre hlbšiu analýzu metrík. Trénovacia časť pozostáva z 20 000 pixelov pre každú kategóriu, a z jedného jedinečného plastu bolo odobraných presne 1 000 vzoriek. Validácia množina o celkovom rozsahu 10 000 pixelov je v tomto prípade zostavená výhradne z pixelov získaných z úplne iných kusov plastového odpadu, než aké sa nachádzali v trénovacej množine. Tento prístup umožňuje objektívne posúdiť spoľahlivosť klasifikátora pri kontakte s novým plastom.

2.2 Návrh a trénovanie klasifikačného modelu

V tejto časti práce sa venujeme implementácii metódy, ktorá dokáže na základe spracovaného spektra identifikovať druh plastu. Vzhľadom na charakter hyperspektrálnych dát, kde sú susedné vlnové dĺžky silne korelované, sme zvolili metódu Partial Least Squares Discriminant Analysis. Tento algoritmus je efektívny pri redukcii dimenzionality a zároveň hľadá komponenty, ktoré vysvetľujú najväčšiu varianciu medzi spektrálnymi príznakmi a cieľovými triedami.[17]Metóda PLS-DA je taktiež používaná firmou Specim na triedenie plastového odpadu.

Pre zabezpečenie znovupoužiteľnosti a čistoty kódu sme celú logiku klasifikácie zapuzdрили do triedy `PlasticClassifierPLS`. Toto riešenie umožňuje uchovať model, proces kódovania štítkov aj predprocesing v rámci jedného objektu.

Algoritmus 2.3: Inicializácia modelu

```

self.model = PLSRegression(n_components=15)
# Inicializácia PLS regresie s 15 latentnými premennými,

self.encoder = OneHotEncoder(sparse_output=False)
# Inicializácia kódovača na transformáciu názvov tried
# na indikátorovú maticu (One-Hot), ktorú vyžaduje PLS model.

```

Pred vstupom do modelu prechádzajú dáta transformáciou, ktorá kombinuje vyhladenie a výpočet derivácie v jednom kroku. Tento prístup je rýchlejší a presnejší ako samotná derivácia pomocou knižnice numpy.

Algoritmus 2.4: Metódy pre predspracovanie a tréning modelu

```

def preprocess(self, spectrum):
    # savgol_filter vyhladí signál polynómom a zároveň vypočíta deriváciu (deriv=1).
    return savgol_filter(spectrum, window_length=15, polyorder=2,
                        deriv=1, axis=-1)

def train(self, X_train, y_labels):
    # Transformácia štítkov na One-Hot maticu a uloženie názvov
    # tried
    y_labels = np.array(y_labels).reshape(-1, 1)
    y_encoded = self.encoder.fit_transform(y_labels)
    self.classes_ = self.encoder.categories_[0]
    # Spektrálna úprava dát a samotné trénovanie modelu
    X_proc = self.preprocess(X_train)
    self.model.fit(X_proc, y_encoded)

```

Použitie funkcie `savgol_filter` s parametrom `deriv=1` umožňuje vypočítať deriváciu priamo z vyhladeného signálu. Tento prístup zabezpečuje stabilitu spektrálnych príznakov, pretože eliminuje vysokofrekvenčný šum ešte pred samotným derivačným krokom. Prevod textových štítkov pomocou `OneHotEncoder` následne transformuje kategórie do binárnej matice, čo je nevyhnutný formát pre korektné fungovanie algoritmu PLS-DA pri klasifikácii viacerých tried súčasne.

Keďže výstupom PLS regresie sú spojené numerické hodnoty, pre klasifikáciu vzoriek do konkrétnych kategórií využívame funkciu `argmax`. Táto funkcia priradí vzorke názov tej triedy, ktorá v predikcii dosiahla najvyššie skóre.

Algoritmus 2.5: Logika klasifikácie neznámych vzoriek

```

def predict(self, X_raw):
    X_proc = self.preprocess(X_raw)
    # Predspracovanie vstupných dát

    prediction = self.model.predict(X_proc)
    # Výpočet skóre pre všetky triedy

```

```

class_indices = np.argmax(prediction, axis=1)
# Výber indexu triedy s najvyššou predikovanou hodnotou

return self.classes_[class_indices]
# Prevod číselných indexov späť na textové názvy plastov

```

2.3 Logistická regresia

Okrem metódy PLS-DA sme v rámci práce implementovali a otestovali aj klasifikátor založený na logistickej regresii. Tento prístup predstavuje štatistickú metódu, ktorá modeluje pravdepodobnosť príslušnosti vzorky k danej triede pomocou logistickej funkcie. Na rozdiel od PLS-DA, logistická regresia nepracuje priamo s redukciou dimenzionality, ale optimalizuje váhy pre všetky vstupné príznaky súčasne.

2.3.1 Implementácia triedy PlasticClassifierLogistic

Pre zachovanie konzistencie s predchádzajúcim experimentom sme algoritmus zapuzdрили do triedy PlasticClassifierLogistic.

Algoritmus 2.6: Inicializácia modelu logistickej regresie

```

self.model = LogisticRegression(
    multi_class='multinomial',
    solver='lbfgs',
    max_iter=1000
)
# multi_class='multinomial' určuje využitie algoritmu pre viac
# než dve triedy.
# solver='lbfgs' je optimalizačný algoritmus (Limited-memory
# Broyden-Fletcher-Goldfarb-Shanno) vhodný pre multiclass problémy.
# max_iter=1000 zvyšuje limit opakovaní, aby algoritmus stihol
# nájsť minimum chybovej funkcie.

self.scaler = StandardScaler()
# Inicializácia skálera na normalizáciu dát,
# čo zabezpečí, že všetky vlnové dĺžky budú mať porovnateľnú mierku.

```

Logistická regresia je citlivá na rozsah hodnôt vstupných príznakov. Ak by mali jednotlivé vlnové dĺžky výrazne odlišné amplitúdy, model by mohol prioritizovať určité časti spektra len na základe ich mierky.

Algoritmus 2.7: Predspracovanie signálu a škálovanie

```

def preprocess(self, spectrum):
    return savgol_filter(spectrum, window_length=15,
        polyorder=2, deriv=1, axis=-1)

```

```
def train(self, X_train, y_labels):
    X_proc = self.preprocess(X_train)
    X_scaled = self.scaler.fit_transform(X_proc)
    # fit_transform vypočíta priemer a odchýlku pre každý kanál
    # a následne ich pretransformuje na štandardizovanú mierku.

    self.model.fit(X_scaled, y_labels)
    # Hľadanie koeficientov, ktoré najlepšie oddeľujú spektrá
    # jednotlivých plastov v transformovanom priestore.
```

Pri predikcii musia nové dáta prejsť identickým reťazcom transformácií ako tréningová množina. Využitie metódy `predict` priamo vracia názov triedy s najvyššou vypočítanou pravdepodobnosťou.

Algoritmus 2.8: Metóda pre klasifikáciu nových vzoriek

```
def predict(self, X_raw):
    X_proc = self.preprocess(X_raw)

    if X_proc.ndim == 1:
        X_proc = X_proc.reshape(1, -1)

    X_scaled = self.scaler.transform(X_proc)
    # Transformácia nových dát pomocou priemerných hodnôt,
    # ktore si model zapamätal počas fázy trénovania.

    return self.model.predict(X_scaled)
    # Určenie výslednej triedy plastu na základe najvyššej
    vypočítanej pravdepodobnosti.
```

2.4 Extreme Gradient Boosted Decision Trees

Ďalším pokročilým prístupom k identifikácii polymérov je využitie algoritmu Extreme Gradient Boosted Decision Trees, konkrétne prostredníctvom knižnice XGBoost. Na rozdiel od lineárnych modelov, XGBoost dokáže zachytiť nelineárne vzťahy medzi vlnovými dĺžkami.

2.4.1 Implementácia triedy `PlasticClassifierXGB`

Model je zapuzdrený v triede `PlasticClassifierXGB`, ktorá integruje predspracovanie, trénovanie s validáciou a finálnu predikciu.

Algoritmus 2.9: Inicializácia modelu XGBoost

```
self.model = XGBClassifier(
    n_estimators=300,
    learning_rate=0.1,
    max_depth=6,
    tree_method='hist',
```

```

        device="cuda",
        random_state=42
    )
    # n_estimators=300 definuje počet rozhodovacích stromov
    # learning_rate=0.1 určuje veľkosť kroku aktualizácie váh
    # max_depth=6 limituje hĺbku stromov
    # tree_method='hist' využíva histogramovú aproximáciu splitov
    # device="cuda" presúva výpočty na GPU pre urýchlenie
    # tréningového procesu.

```

[6]Vektorová normalizácia transformuje spektrá na jednotkovú dĺžku, čím eliminuje rozdiely v intenzite spôsobené tieňmi alebo geometriou povrchu. Tento krok zabezpečuje, že model klasifikuje materiály na základe relatívnych pomerov vlnových dĺžok a nie na základe ich absolútneho jas. Následná prvá derivácia pomocou Savitzky-Golay filtra zvýrazňuje charakteristické absorpčné pásy a potláča aditívny posun pozadia.

Algoritmus 2.10: Vektorová normalizácia a výpočet derivácií

```

def preprocess(self, spectrum):
    norm = np.linalg.norm(spectrum, axis=1, keepdims=True)
    X_norm = spectrum / norm
    # Vektorová normalizácia delí každé spektrum jeho normou

    return savgol_filter(X_norm, window_length=15,
        polyorder=3, deriv=1, axis=-1)

```

Trénovanie modelu zahŕňa transformáciu textových cieľových kategórií na číselné indexy a následné monitorovanie úspešnosti na nezávislej validačnej sade.

Algoritmus 2.11: Trénovanie s monitorovaním validácie

```

def train(self, X_train, y_labels, X_val, y_val):
    y_train_enc = self.label_encoder.fit_transform(y_labels)
    # Prevod názvov plastov na číselnú reprezentáciu.

    X_train_scaled = self.scaler.fit_transform(X_train_proc)
    # Standartizácia príznakov

    self.model.fit(
        X_train_scaled, y_train_enc,
        eval_set=[(X_val_scaled, y_val_enc)],
        verbose=True
    )
    # Trénovanie s eval_set umožňuje sledovať pokles chyby
    # na validačných dátach v reálnom čase, čo indikuje,
    # kedy je model optimálne natrénovaný.

```

Po úspešnom natrénovaní modelu na stabilizovaných dátach nasleduje fáza inferencie. V nej model aplikuje naučené rozhodovacie pravidlá na neznáme spektrá, pričom výsledkom je

opäť textová identifikácia materiálu.

Algoritmus 2.12: Predikcia

```
def predict(self, X_raw):
    X_proc = self.preprocess(X_raw)
    X_scaled = self.scaler.transform(X_proc)
    preds = self.model.predict(X_scaled)

    return self.label_encoder.inverse_transform(preds)
# Vráti číslo, ktoré reprezentuje druh plastu.
```

2.5 Implementácia validačného a porovnávacieho skriptu

Pre objektívne zhodnotenie kvality klasifikácie a výpočtovej náročnosti sme vytvorili komplexný testovací skript, ktorý v jednotnom prostredí porovnáva modely PLS-DA, logistickú regresiu a GBDT. Program je navrhnutý pre automatizované tréningovanie na primárnom data-sete a následnú validáciu na nezávislej sade dát, pričom sa zameriava na štatistickú úspešnosť a latenciu spracovania.

2.5.1 Meranie výkonnostných metrík a simulácia push-broom snímania

Skript prechádza cez definované konfigurácie a pre každú kombináciu vypočítava kľúčové ukazovatele pomocou knižnice `scikit-learn`. Na rozdiel od jednoduchého priemerovania využíva skript vážené priemerovanie, ktoré pri výpočte výslednej metriky zohľadňuje početnosť zastúpenia jednotlivých tried plastov vo validačnej sade, naše validačné množiny sú však všetky rovnakej veľkosti.

Algoritmus 2.13: Výpočet klasifikačných metrík a simulácia latencie

```
# Výpočet celkovej presnosti a vážených metrík pre všetky kategórie
acc = accuracy_score(y_val, y_pred_val)
precision, recall, f1, _ = precision_recall_fscore_support(
    y_val, y_pred_val, average='weighted'
)

# Simulácia času spracovania po riadkoch (640 pixelov na riadok)
line_durations = []
for i in range(num_val_lines):
    # Výber bloku dát zodpovedajúceho šírke senzora SCANLINE_WIDTHH
    row = X_val[i * SCANLINE_WIDTHH: (i + 1) * SCANLINE_WIDTHH]

    t_start = time.perf_counter()
    _ = model.predict(row) # Vykonalie predikcie pre celý riadok
    t_end = time.perf_counter()

    line_durations.append(t_end - t_start)
```

```
# Prevod priemerného času spracovania jedného riadka na milisekundy  
avg_line_ms = np.mean(line_durations) * 1000
```

Kľúčovým parametrom simulácie je `SCANLINE_WIDTH = 640`, čo predstavuje reálne rozlíšenie senzora v jednej línii. Skript vypočítava celočíselný počet plných riadkov obsiahnutých vo validačnej množine, čím zabezpečuje presné meranie času potrebného na spracovanie ucelenej skenovacej línie. Tento údaj (`ms/riadok`) je kritický pre posúdenie schopnosti modelu pracovať v reálnom čase pri konkrétnej rýchlosti dopravníkového pásu.

Všetky získané dáta sú tabuľkovo spracované do štruktúry `pandas DataFrame`. Výsledná tabuľka obsahuje porovnanie úspešnosti v percentách a časovú náročnosť s presnosťou na štyri desatinné miesta, čo poskytuje optimálny podklad pre výber optimálneho modelu z hľadiska pomeru presnosti a rýchlosti.

Algoritmus 2.14: Formátovanie a uloženie výsledkov do zoznamu

```
results.append({  
    "Algoritmus": cfg["algo"],  
    "Pásma": cfg["label"],  
    "Accuracy": f"{acc*100:5.2f}",  
    "Precision": f"{precision:5.3f}",  
    "Recall": f"{recall:5.3f}",  
    "F1": f"{f1:5.3f}",  
    "ms/riadok": f"{avg_line_ms:7.4f}"  
})
```

Kapitola 3

Interpretácia výsledkov a analýza modelu

3.1 Analýza separability dát pomocou t-SNE

Ešte pred samotným testovaním klasifikačných modelov je dôležité preskúmať vnútornú štruktúru získaných hyperspektrálnych dát a identifikovať potenciálne problematické kategórie. Pre vizualizáciu vysokorozmerného priestoru do 2D roviny sme zvolili metódu t-SNE. Na rozdiel od lineárnych metód, ako je PCA, t-SNE dokáže zachytiť zložité nelineárne vzťahy a zobrazíť prirodzené zhluky v dátach na základe ich vzájomnej podobnosti.


Na výpočet bola použitá trénovacia množina otvoreného datasetu, ktorá obsahuje 20 000 spektrálnych profilov pre každú kategóriu plastu. Vzhľadom na vysokú dimenzionalitu dát sme pred samotnou t-SNE transformáciou aplikovali PCA na redukcii počtu dimenzií na 50 komponentov, čím sa dosiahla vyššia výpočtová stabilita.

Algoritmus 3.1: Výpočet nelineárneho vnorenia t-SNE

```
# PCA odstráni šum a zníži 224 kanálov na 50 komponentov
pca = PCA(n_components=50)
X_pca = pca.fit_transform(X_all)

# t-SNE vytvorí 2D mapu
# random_state: zabezpečí, že výsledný graf bude pri každom spustení
# rovnaký
tsne = TSNE(n_components=2, perplexity=30, random_state=42)
X_embedded = tsne.fit_transform(X_pca)
```

PCA zredukuje spektrum na 50 najvýznamnejších lineárnych kombinácií príznakov. Algoritmus t-SNE následne tieto dáta nelineárne projektuje do dvoch rozmerov, pričom parameter perplexity určuje rovnováhu medzi snahou zachovať lokálne okolie bodov a globálnu štruktúru celého datasetu.



Obr. 3.1: 2D Vizualizácia hyperspektrálnych dát pomocou t-SNE

Výsledná vizualizácia (Obr. 3.1) poskytuje dôležitý vhľad do náročnosti klasifikačnej úlohy. Hodnoty na osiach X a Y v rozsahu približne -100 až 100 nepredstavujú fyzikálne veličiny, ale abstraktné súradnice v nelineárnom priestore. Interpretácia grafu sa preto sústreďí na relatívnu vzdialenosť a hustotu zobrazených bodov:

- **Kritické prekryvy:** Výrazným javom na mape je masívne pretínanie kategórie **PP** (červená farba) s kategóriou **LDPE** (oranžová farba). Keďže sa tieto body nachádzajú v blízkych súradniciach, ich spektrálne charakteristiky sú v meranom rozsahu takmer identické. Vysoká spektrálna kolinearita medzi týmito dvoma materiálmi v nameranom rozsahu naznačuje, že ich podpisy sú pre lineárne modely takmer identické, čo predpo-vedá zvýšenú mieru zámen v neskoršej klasifikácii.
- **Separabilita kategórií:** Naopak, materiály ako **PET** či **HDPE** tvoria relatívne jasne definované a oddelené skupiny, čo naznačuje ich dobrú identifikovateľnosť klasifikačnými modelmi.

Táto vizuálna analýza slúži ako teoretický základ pre pochopenie neskoršie nameraných hodnôt v maticiach zámen jednotlivých modelov.

3.2 Výsledky klasifikačnej metódy PLS-DA

Na praktické overenie úspešnosti modelu v reálnych podmienkach sme vytvorili skript, ktorý vykonáva klasifikáciu celých hyperspektrálnych snímok. Program spracováva surové dáta, aplikuje radiometrickú kalibráciu a následne čistí výsledok pomocou priestorovej filtrácie, čím eliminuje artefakty typické pre tento druh snímania.

3.2.1 Načítanie a predspracovanie dát

Hyperspektrálne kocky môžu dosahovať veľkosti niekoľkých gigabajtov, čo znemožňuje ich priame načítanie do operačnej pamäte RAM. V programe využívame metódu `open_memmap` z knižnice `spectral`, ktorá umožňuje pristupovať k binárnym dátam na disku bez ich celkového načítania.

Algoritmus 3.2: Využitie memory mappingu pre prácu s veľkými dátami

```
# Otvorenie dát pomocou memory mappingu pre efektívnu prácu s pamäťou
hsi_data = img_hsi.open_memmap(writable=False)

# Spracovanie prebieha iteratívne po riadkoch obrazu
for r in range(rows):
    # Načítanie jedného riadka zo spektrálnej kocky priamo z disku
    row_data = hsi_data[r, :, :].astype(float)
```

Každý načítaný riadok musí byť pred vstupom do modelu normalizovaný. Kalibrácia prebieha pomocou vopred nasnímanej čiernej a bielej referencie. Na rozdiel od jednoduchého ošetrenia delenia nulou tu využívame funkciu `np.where`, ktorá je výpočtovo efektívnejšia pre veľké polia.

Algoritmus 3.3: Kalibrácia a ošetrenie delenia nulou

```
denom = np.where((white_ref - dark_ref) == 0, 1, white_ref - dark_ref)

# Prevod surových dát na hodnoty odrazivosti
row_refl = np.nan_to_num((row_data - dark_ref) / denom)
```

V rámci metódy `preprocess` dochádza k úprave signálu tak, aby sa zvýraznili absorpčné črty materiálu a potlačil šum senzora:

Algoritmus 3.4: Spektrálna úprava signálu

```
# Savitzky-Golay filter s prvou deriváciou
return savgol_filter(spectrum, window_length=15, polyorder=2, deriv=1,
    axis=-1)
```

3.2.2 Postprocessing

Z dôvodu globálnej iluminácie môže model vykazovať nízke hodnoty istoty. Ak je skóre priradené najpravdepodobnejšej triede pod zvoleným prahom, pixel identifikujeme ako pozadie

(background), čím eliminujeme vznik vizuálnych artefaktov v klasifikovanej mape.

Algoritmus 3.5: Metóda predikcie s implementovaným prahom istoty

```
def predict(self, X_raw, threshold=0.15):
    X_proc = self.preprocess(X_raw)
    prediction = self.model.predict(X_proc)
    max_scores = np.max(prediction, axis=1)
    # Extrahuje najväčšiu hodnotu skóre pre každý spracovavaný bod.
    indices = np.argmax(prediction, axis=1)
    labels = self.classes_[indices].astype(object)
    # zmena typu na object, aby bolo možné vložiť
    # textový reťazec 'background'.

    labels[max_scores < threshold] = 'background'
    # Ak je najväčšie skóre nízšie ako definovaný prah,
    # pixel je klasifikovaný ako pozadie
    return labels
```

Aplikovaním mediánového filtra zabezpečujeme, že chybné klasifikované pixely v okolí sú nahradené správnymi hodnotami na základe ich susedstva. Výsledná vizualizácia klasifikovaného obrazu je vďaka potlačeniu šumu presnejšia, vizuálne čistejšia a lepšie reprezentuje reálne rozloženie materiálov.

Algoritmus 3.6: Uplatnenie priestorovej filtrácie na výslednú maticu

```
# predict() vracia maticu indexov tried (0, 1, 2...) pre celý
# riadok naraz
idx_matrix[r, :] = clf.predict(row_refl)

# Uplatnenie mediánového filtru o veľkosti 3x3 na maticu
# klasifikovaných indexov
cleaned_idx_matrix = ndimage.median_filter(idx_matrix, size=3)
```


3.2.3 Vizualizácia výsledkov

Posledným krokom je konverzia klasifikovanej matice indexov na vizuálnu RGB mapu pomocou vopred definovanej farebnej mapy.

Algoritmus 3.7: Konverzia indexov na RGB formát

```
for r in range(rows):
    for c in range(cols):
        # Získanie vyčisteného indexu z matice po filtrácii
        idx = cleaned_idx_matrix[r, c]
        # Prevod indexu späť na názov materiálu (napr. PET, PP)
        label = class_list[idx]
        # Priradenie farby na základe identifikovanej triedy
        final_img[r, c] = COLOR_MAP.get(label, COLOR_MAP['background'])
```

Vďaka tomu, že najprv vyčistíme nameraný signál a potom ešte dodatočne vyhladíme výsledný obrázok, sa nám podarilo získať vizuálnu reprezentáciu našich už klasifikovaných plastov.



Obr. 3.2: Porovnanie klasifikácie pomocou predprogramu od Specim a našou klasifikáciou.

Na lepšie zistenie presnosti nášho modelu sme použili confusion matrix, ktorý zobrazuje jednotlivé klasifikované pixely otvoreného datasetu plastov. RGB vizualizácia zobrazuje uzavretý dataset, ktorý slúži čisto na porovnanie originálnej klasifikácie pomocou programu, ktorý funguje na linke a porovnáva sa s našou implementáciou danej metódy.

Tabuľka 3.1: Matica zámien pre finálny klasifikačný model.

	HDPE	LDPE	PET	PP	PS	PVC	pas
HDPE	8907	552	31	17	3	478	12
LDPE	19	7522	406	78	25	257	1693
PET	5	18	9133	8	5	48	783
PP	17	235	67	4765	1051	1301	2564
PS	0	6	34	6	8047	1040	867
PVC	0	4	0	2	2	9992	0
pas	0	0	2	0	0	0	9998

Model dosiahol celkovú úspešnosť **83,38 %**. Vysokú úspešnosť klasifikácie si zachovali kategórie PVC a transportného pásu (pas), ktoré sú takmer bezchybne identifikované. Naopak,

kritickým nedostatkom modelu je trieda PP, ktorá vykazuje výrazne nízky recall. Materiál PP je často nesprávne klasifikovaný ako transportný pás, PVC alebo PS. Značná miera zámen s transportným pásom sa objavuje aj pri triedach LDPE a PS, čo potvrdzuje pretínanie spektrálnej informácie pozadia a tenkých vrstiev polymérov. Problémom je taktiež klasifikácia HDPE, kde dochádza k zlej predikcii do tried LDPE a PVC, čo naznačuje nedostatočnú diskriminačnú schopnosť modelu pri rozlišovaní medzi týmito typmi polymérov v daných podmienkach.


3.2.4 Analýza latentného priestoru a separácie tried pomocou PLS-DA

Pre vizualizáciu schopnosti modelu odlišovať jednotlivé materiály sme implementovali projekciu vysokodimenzionálnych dát do 2D priestoru latentných premenných. Tento proces využíva metódu PLS-DA na nájdenie smerov maximálnej separácie medzi triedami.

Algoritmus 3.8: Výpočet skóre a konfidenčných elíps pre PLS-DA

```
# Transformácia vysokodimenzionálnych spektier do 2D priestoru latentných premenných
X_scores = clf.transform_to_scores(X)

# Vykreslenie súradníc jednotlivých meraní do bodového grafu (Score Plot)
plt.scatter(points[:, 0], points[:, 1], label=material, color=current_color)
```



Obr. 3.3: PLS-DA Score Plot: Vizualizácia separácie jednotlivých materiálov v priestore latentných premenných.

Na obrázku PLS-DA Score Plot môžeme vidieť, ako algoritmus dokáže rozlíšiť jednotlivé druhy plastov na základe ich spektrálnej podobnosti. Každý bod v grafe predstavuje jedno

konkrétne meranie, pričom osi X a Y zobrazujú najdôležitejšie rozdiely, ktoré model v dátach našiel.

Z grafu je jasne vidieť, že niektoré plasty, ako napríklad HDPE, tvoria samostatný zhluk úplne vpravo, čo znamená, že ich spektrum je veľmi špecifické a model ich rozpozná s vysokou istotou. Na druhej strane, v strede grafu môžeme pozorovať miesto, kde sa body materiálov PET, PS, LDPE a PP začínajú viac premiešavať. Práve tento vizuálny prekryv nám vysvetľuje, prečo pri týchto konkrétnych plastoch dochádza v confusion matrixe k občasným chybám – ich spektrá sú si v týchto bodoch jednoducho príliš podobné a pre algoritmus je náročnejšie ich presne odlíšiť.

3.3 Klasifikácia pomocou logistickej regresie a priestorová filtrácia

Ako alternatívny klasifikačný prístup sme implementovali model založený na logistickej regresii. Na rozdiel od PLS-DA, tento model v našej implementácii pracuje s odhadom pravdepodobnosti pre každú triedu na miesto výpočtu skóre, na ktorou funguje PLS-DA.

Tak ako pri PLS-DA aj pri logistickej regresii sme použili threshold, ktorý však teraz nastavuje hranicu istoty.

Algoritmus 3.9: Implementácia predikcie s prahom istoty pre logistickú regresiu

```
def predict(self, X_refl, threshold=0.85):
    # Preprocessing je identický s modelom PLS-DA
    X_proc = self.preprocess(X_refl)

    # Škálovanie dát podľa naučeného scaleru z tréningovej fázy
    X_scaled = self.scaler.transform(X_proc)

    # Výpočet pravdepodobností každej triedy plastu
    probs = self.model.predict_proba(X_scaled)
    # výber plastu s najvyššou pravdepodobnosťou
    max_probs = np.max(probs, axis=1)
    indices = np.argmax(probs, axis=1)

    labels = self.model.classes_[indices].astype(object)
    labels[max_probs < threshold] = 'background'
    return labels
```

V kóde využívame parameter `CONFIDENCE_THRESHOLD = 0.85`. To znamená, že ak model nepriradí žiadnemu plastu pravdepodobnosť aspoň 85 %, pixel je automaticky klasifikovaný ako background.

Spracovanie prebieha iteratívne po riadkoch, kde sa priradí index každému danému pixelu.

Algoritmus 3.10: Klasifikácia daného pixelu

```
for c in range(cols):
```

```

label = row_labels[c]
# Ak je pixel pod prahom istoty
if label == 'background':
    idx_matrix[r, c] = 99 # Kód pre pozadie
else:
    idx_matrix[r, c] = class_list.index(label)

```

Tak ako pri PLS-DA aj pri logistickej regresii môžu nastať artefakty alebo zle klasifikované pixely.

Algoritmus 3.11: Aplikácia priestorového čistenia

```

cleaned_idx = ndimage.median_filter(idx_matrix, size=3)

```

Ako však vidíme na (Obr. 3.4), naše klasifikovanie pomocou logistickej regresie presnejšie klasifikuje pixely, ktoré boli originálne klasifikované ako background. Dôvodom je pravdepodobne nastavenie thresholdu, ktorý nemeníme individuálne na jednotlivých druhoch polymérov.



Obr. 3.4: Porovnanie pôvodnej scény a výsledku klasifikácie logistickou regresiou.

Dosiahnutá celková úspešnosť modelu logistickej regresie na validačnom datasete predstavuje **93,82 %**. Trénovacia množina pozostávala z 20 000 pixelov pre každú triedu.

Tabuľka 3.2: Matica zámien pre model logistickej regresie.

	HDPE	LDPE	PET	PP	PS	PVC	pas
HDPE	8950	1028	3	9	0	10	0
LDPE	53	9880	13	24	0	1	29
PET	15	8	9961	0	5	0	11
PP	33	75	63	7135	1292	227	1175
PS	9	2	98	12	9815	9	55
PVC	1	1	0	3	0	9995	0
pas	0	58	1	0	0	0	9941

Analýza klasifikácie logistickou regresiou


Z matice zámien (Tab. 3.2) vyplýva, že model exceluje pri identifikácii PVC, PET a transportného pásu. Napriek vysokej úspešnosti pri iných triedach model vykazuje nižšiu presnosť pri triede LDPE. Tento jav je spôsobený tým, že do triedy LDPE bolo nesprávne zaradených

až 1028 pixelov, ktoré v skutočnosti patria do kategórie HDPE. To naznačuje, že spektrálny podpis HDPE je často vyhodnotený ako LDPE.

Najvýraznejší klasifikačný problém predstavuje trieda PP, ktorá vykazuje nízky recall. Model dokázal správne identifikovať len 7135 vzoriek tejto triedy, pričom dochádzalo k masívnym zámenám s triedami PS a transportným pásom. Tento vysoký počet falošne negatívnych výsledkov pre PP naznačuje, že spektrálna charakteristika PP je v meranom rozsahu náchylná na prekryv s inými polymérmi a pozadím, čo vedie k neúplnému zachyteniu tejto triedy.

3.3.1 Analýza spektrálnej významnosti logistickej regresie

Graf dôležitosti kanálov pre logistickú regresiu (Obr. 3.5) ukazuje, že model sa pri rozhodovaní sústreďuje na špecifické oblasti spektra.



Obr. 3.5: Suma absolútnych hodnôt koeficientov logistickej regresie identifikujúca kritické vlnové dĺžky.

Najvyššiu dôležitosť vykazujú kanály v oblastiach:

- **Zhluk K72 – K79:** Logistická regresia vníma tieto kanály ako najdôležitejšie, a keďže ich je viac pri sebe, určitý úsek kanálov je dobrý kandidát na náhradu za všetkých 224 kanálov.
- **Výrazný vrchol K204 a K207:** Kanály majú síce veľkú váhu pri klasifikovaní, no vrcholov je signifikantne menej ako v zhluku od K72 - K79.

3.3.2 Optimalizácia klasifikácie zúžením spektrálneho rozsahu

V nadväznosti na predchádzajúcu analýzu dôležitosti kanálov sme implementovali úpravu klasifikačného procesu, ktorá spočíva v orezaní vstupných dát na najvýznamnejšiu oblasť spektra. Cieľom bolo overiť, či dokážeme udržať kvalitu triedenia aj pri výrazne nižšom počte vstupných premenných.

Úprava algoritmu pre orezané spektrum

Zmena v kóde sa dotkla inicializácie triedy a metódy `preprocess`. Do konštruktora sme zaviedli parametre `start_band` a `end_band`, ktoré definujú hranice spracovávaného okna.

Algoritmus 3.12: Úprava triedy pre prácu s výsekcom spektra


```
def __init__(self, start_band=40, end_band=80):
    # Definícia rozsahu kanálov
    self.start_band = start_band
    self.end_band = end_band

def preprocess(self, spectrum):
    # Výber konkrétnych kanálov
    cropped = spectrum[:, self.start_band:self.end_band]
    return savgol_filter(cropped, window_length=15, polyorder=2, deriv
                        =1, axis=-1)
```

Tento prístup zabezpečuje, že model po natrénovaní na kanáloch 40 až 80 očakáva na vstupe pri každej predikcii len tento konkrétny úsek.

3.3.3 Analýza spektrálnych charakteristík

Na obrázku 3.6 sú zobrazené priemerné surové dáta odrazivosti pre jednotlivé druhy polymérov, ktoré boli iba znormalizované. A na druhom grafe je priemerná odrazivosť predspracovaná pomocou Savitzsky-Golay filtru a prvou deriváciou.




Obr. 3.6: Priemerná odrazivosť polymérov.

Z hľadiska diskriminácie materiálov je kritická oblasť medzi kanálmi 60 až 80. V tomto úseku môžeme pozorovať unikátne správanie polyméru PS. Zatiaľ čo derivácia väčšiny ostatných materiálov v tomto rozsahu nadobúda záporné hodnoty, krivka PS prudko stúpa do kladných hodnôt. Tento špecifický výkyv vytvára pre PS jedinečný spektrálny podpis.

3.4 Vyhodnotenie výsledkov s redukovaným spektrom


V nasledujúcej časti sú analyzované výsledky klasifikácie pri redukcii počtu spektrálnych kanálov. Pre vizualizáciu dôležitosti jednotlivých pásiem používame plasty z otvoreného datasetu, pričom pre najlepšiu demonštráciu vplyvu orezania bol zvolený druh plastu PS.

Pri použití všetkých dostupných kanálov dosiahol model s využitím logistickej regresie celkovú úspešnosť **93,82 %**.



Obr. 3.7: Klasifikácia PS pri zachovaní všetkých spektrálnych kanálov.


Druhý experiment využíval rozsah kanálov 40 – 80, kde celková úspešnosť klesla na **90,3 %**.



Obr. 3.8: Klasifikácia PS pri redukcii na kanály 40 – 80.

Na obrázku 3.8 je viditeľné, že štvrtý a piaty plast vykazujú nárast počtu pixelov, ktoré mali byť klasifikované ako PS, avšak kvôli ich priehľadnosti má metóda s korektnou identifikáciou problémy. Trieda PS dosiahla v tomto nastavení Precision 84,97 %, Recall 88,43 % a F1-score 86,67 %.

Posledný experiment bol zameraný na rozsah kanálov 100 – 180.



Obr. 3.9: Klasifikácia PS pri orezaní na kanály 100 – 180.

V tomto prípade model v oblastiach výskytu plastov zlyháva v identifikácii odpadu ako celistvého objektu. Výsledky triedy PS sú drasticky horšie: Precision 74,89 %, Recall 75,64 % a F1-score 75,26 %. Je dôležité zdôrazniť, že aj napriek použitiu 80 kanálov (čo je dvojnásobok oproti predchádzajúcemu experimentu) sú výsledky výrazne slabšie, čo potvrdzuje nízku informačnú hodnotu spektra v danom rozsahu pre tento typ polyméru.

3.4.1 Klasifikácia pomocou Extreme Gradient Boosted Decision Trees

Model bol trénovaný na otvorenom datasete s rozsahom 20 000 vzoriek pre každú kategóriu plastu a následne validovaný na nezávislom súbore 10 000 pixelov, ktoré pochádzali z fyzicky odlišných kusov materiálu. Dosiahnutá celková úspešnosť modelu predstavovala **94,15 %**.

Tabuľka 3.3: Matica zámien pre model XGBDT (XGBoost)

	HDPE	LDPE	PET	PP	PS	PVC	pas
HDPE	8980	1008	0	10	1	1	0
LDPE	141	9825	0	7	0	0	27
PET	0	150	9835	0	7	1	7
PP	2	717	13	7679	1127	24	438
PS	0	52	55	47	9616	3	227
PVC	0	1	0	11	2	9986	0
pas	0	14	1	0	0	0	9985

Analýza výsledkov (Tab. 3.3) ukazuje, že celková úspešnosť je mierne vyššia v porovnaní s logistickou regresiou, pričom model vykazuje podobné správanie pri väčšine kategórií. Kľúčový rozdiel však nastáva pri najproblematickejšej kategórii **PP**.

Zatiaľ čo logistická regresia dosiahla pri materiáli PP *recall* na úrovni 71,35 %, model XGBDT dokázal správne identifikovať 7 679 vzoriek, čo predstavuje nárast *recallu* na **76,79 %**. Tento posun o viac ako 5 % je spôsobený schopnosťou algoritmu XGBoost lepšie rozlíšiť materiál PP v oblastiach, kde dochádza k spektrálnemu prekryvu s polymérom PS. Hoci k

zámenám medzi PP a PS stále dochádza, nelineárne rozhodovacie hranice stromov dokázali túto separáciu spresniť efektívnejšie než lineárna pravdepodobnostná funkcia logistickej regresie. Kategória HDPE vykazuje stabilnú mieru zámeny s LDPE, čo potvrdzuje ich vysokú spektrálnu príbuznosť naprieč všetkými testovanými modelmi. Na vizualizácii t-SNE (Obr. 3.1) je taktiež jasne identifikovateľná okrajová oblasť, kde zhluk **LDPE** (oranžová farba) plynule zasahuje do hustejšieho jadra kategórie **HDPE** (modrá farba). Tento vizuálny prekryv v latentnom priestore priamo odôvodňuje zvýšenú mieru chybovosti a vzájomné zámeny týchto dvoch polymérov vo výsledných maticiach zámen. Potvrdzuje sa tým predpoklad, že existujú prechodové spektrálne stavy, pri ktorých lineárna aj nelineárna separácia naráža na fyzikálne limity podobnosti spektrálnych podpisov týchto materiálov.

3.5 Analýza výpočtovej náročnosti klasifikačných modelov

Pre úspešné nasadenie algoritmov v priemyselnom prostredí s rýchlo sa pohybujúcimi dopravníkovými pásmi je kritickým parametrom časová zložitosť predikcie. V tejto sekcii analyzujeme teoretickú náročnosť jednotlivých modelov pomocou asymptotickej notácie O . Uvažujeme vstupnú maticu dát s rozmermi $P \times K$, kde P predstavuje celkový počet pixelov v snímanej scéne a K počet spektrálnych kanálov. Počet klasifikačných tried označujeme ako L .

3.5.1 Náročnosť predspracovania dát Savitzky-Golay filtra

Všetky implementované modely využívajú v rámci predspracovania Savitzky-Golay filter na vyhladenie signálu a výpočet derivácie. Náročnosť tejto operácie je definovaná ako:

$$O(P \cdot K \cdot W) \quad (3.1)$$

Kde W predstavuje šírku konvolyčného okna. Každý spektrálny bod každého pixelu musí byť prenasobený koeficientom lokálneho polynómu v rámci zvoleného okna. Keďže ide o konvolyčnú operáciu vykonávanú lineárne nad celou dátovou kockou, predspracovanie predstavuje fixnú réžiu nezávislú od zvoleného klasifikátora.

3.5.2 Teoretická zložitosť predikčných modelov

Pri porovnávaní modelov sa zameriavame na predikciu už natrénovaných váh uložených v binárnych súboroch.

[6][14]**Logistická regresia:** Zložitosť predikcie je definovaná vzťahom $O(P \cdot K \cdot L)$. Výpočet spočíva v maticovom násobení vstupných dát s váhami modelu pre každú triedu. Pre každý z P pixelov sa vykonáva skalárny súčin vektora o dĺžke K s vektormi L tried.

[8]**PLS-DA:** Časová náročnosť je definovaná ako $O(P \cdot (K \cdot C + C \cdot L))$, kde C je počet latentných komponentov. Algoritmus najprv projektuje pôvodné príznaky do redukovaného priestoru o rozmere C . Keďže v hyperspektrálnej analýze platí, že $C \ll K$, krok projekcie výrazne znižuje objem dát vstupujúcich do záverečnej klasifikácie. V praxi ide o dve po sebe idúce operácie maticového násobenia.

XGBDT: Zložitosť je určená štruktúrou lesa ako $O(P \cdot T \cdot D)$, kde T je počet stromov a D ich maximálna hĺbka. Na rozdiel od lineárnych modelov, predikcia v GBDT nevykonáva operácie nad všetkými kanálmi K súčasne. Každý pixel prechádza sekvenciou rozhodovacích podmienok v uzloch stromov. Napriek absencii priamej závislosti od K vo fáze inferencie, logické vetvenie v stovkách stromov spôsobuje vyššiu režijnú náročnosť na predikciu.

3.5.3 Vyhodnotenie efektivity

Na základe teoretickej analýzy možno konštatovať, že modely logistickej regresie a PLS-DA sú si výpočtovo veľmi podobné, nakoľko oba algoritmy sú vo fáze klasifikácie založené na lineárnych operáciách. V podmienkach tejto práce vykazujú oba modely porovnateľnú priepustnosť dát, pričom empirické merania naznačujú miernu časovú výhodu v prospech **PLS-DA**. Model PLS-DA by sa stal signifikantne rýchlejšim v porovnaní s logistickou regresiou pri použití výrazne vyššieho počtu klasifikačných tried (L), kedy by sa naplno prejavila výhoda dimenzionálnej redukcie.

Teoreticky najnáročnejšou metódou zostáva **GBDT**, čo vyplýva z potreby prechádzania rozsiahlou štruktúrou rozhodovacích stromov pre každý spracovávaný pixel.

3.6 Celkové vyhodnotenie a porovnanie modelov

V tejto časti interpretujeme dosiahnuté výsledky klasifikačných modelov na otvorenom data-sete. Hlavným kritériom hodnotenia je nielen schopnosť presnej identifikácie polymérov, ale aj časová náročnosť procesu, ktorá je v priemyselnom prostredí kľúčová.

Tabuľka 3.4: Finálne výsledky a časová náročnosť klasifikácie jedného riadka obrazu (640 px)

Algoritmus	Pásma	Úspešnosť (%)	Presnosť	Úplnosť	F1	ms/riadok
PLS-DA	Full	83,38	0,870	0,834	0,830	2,2371
PLS-DA	40-80	83,30	0,866	0,833	0,829	1,9236
LR	Full	93,82	0,943	0,938	0,936	2,4791
LR	40-80	91,00	0,917	0,910	0,907	2,0466
XGBDT	Full	95,53	0,958	0,955	0,954	17,5342
XGBDT	40-80	93,79	0,941	0,938	0,937	11,3386

Z výsledkov v tabuľke 3.4 vyplýva, že najvyššiu úspešnosť 95,53 % dosiahol model **XGBDT** pri použití plného spektra. Avšak z hľadiska latencie vykazuje tento model signifikantne slabšie výsledky. Klasifikácia jedného riadka trvá približne 17,5 ms, čo je v porovnaní s metódami **PLS-DA** a **LR** až sedemnásobne viac.

Aj keď sú namerané časy v milisekundách ovplyvnené výkonom lokálneho procesora použitého pri testovaní, potvrdzujú teoretické predpoklady o vyššej výpočtovej zložitosti nelineárnych rozhodovacích stromov. Pri požiadavke na nasadenie v systémoch s vysokou rýchlosťou dopravníkového pásu sa preto ako optimálnejší kandidát javí **logistická regresia**, ktorá dosahuje vysokú úspešnosť (93,82 %) pri zachovaní nízkej latencie (2,48 ms/riadok).

3.6.1 Detailné výsledky metódy PLS-DA

Metóda PLS-DA slúži ako základný porovnávaci model. Hoci vykazuje najnižšiu latenciu, jej schopnosť separácie niektorých tried je obmedzená lineárnou povahou algoritmu v kombinácii s redukciou dimenzionality.

Tabuľka 3.5: Metriky metódy PLS-DA podľa tried (Full spectrum)

Materiál	Presnosť (%)	Úplnosť (%)	F1-Score (%)	Vzoriek
HDPE	99,54	89,07	94,02	10 000
LDPE	90,22	75,22	82,04	10 000
PET	94,42	91,33	92,85	10 000
PP	97,72	47,65	64,06	10 000
PS	88,11	80,47	84,12	10 000
PVC	76,18	99,92	86,45	10 000
pas	62,81	99,98	77,15	10 000

3.6.2 Detailné výsledky Logistickej regresie

Logistická regresia priniesla výrazné zlepšenie takmer vo všetkých metrikách pri zachovaní porovnateľnej rýchlosti spracovania s PLS-DA.

Tabuľka 3.6: Metriky Logistickej regresie podľa tried (Full spectrum)

Materiál	Presnosť (%)	Úplnosť (%)	F1-Score (%)	Vzoriek
HDPE	98,77	89,50	93,91	10 000
LDPE	89,40	98,80	93,86	10 000
PET	98,24	99,61	98,92	10 000
PP	99,33	71,35	83,05	10 000
PS	88,33	98,15	92,98	10 000
PVC	97,59	99,95	98,76	10 000
pas	88,67	99,41	93,73	10 000

3.6.3 Detailné výsledky metódy XGBDT

Model založený na nelineárnych rozhodovacích stromoch dosiahol najvyššiu celkovú úspešnosť klasifikácie. Vďaka zachytávaniu komplexných vzťahov medzi vlnovými dĺžkami dokázal lepšie separovať spektrálne blízke materiály.

3.6.4 Analýza úspešnosti klasifikácie a problematických materiálov

Detailný pohľad na metriky jednotlivých tried odhaľuje rozdiely v správaní modelov pri konkrétnych polyméroch. Pozorujeme, že vysoká celková úspešnosť modelu nemusí vždy znamenať rovnomernú presnosť pre všetky materiály.

Tabuľka 3.7: Metriky metódy XGBDT podľa tried (Full spectrum)

Materiál	Presnosť (%)	Úplnosť (%)	F1-Score (%)	Vzoriek
HDPE	98,43	89,80	93,92	10 000
LDPE	83,50	98,25	90,27	10 000
PET	99,30	98,35	98,82	10 000
PP	99,03	76,79	86,50	10 000
PS	89,43	96,16	92,67	10 000
PVC	99,71	99,86	99,79	10 000
pas	93,46	99,85	96,55	10 000

- **PS a spektrálna redukcia:** Analýza potvrdila, že trieda PS je vysoko naviazaná na kanály 40 až 80, čo predstavuje vlnové dĺžky v rozsahu 1074 nm až 1213 nm. Pri redukcii spektra na tento úzky rozsah si modely zachovali vysokú úspešnosť identifikácie, čo potvrdzuje existenciu jedinečných spektrálnych absorpčných pásov polystyrénu v tejto oblasti.
- **Metódy a separácia PS:** Medzi modelmi PLS-DA a logistickou regresiou je najväčší rozdiel badateľný práve pri plaste PS. Pri použití celého spektra mala metóda PLS-DA úplnosť na úrovni 80 %, zatiaľ čo pri logistickej regresii táto hodnota vzrástla až na 98 %.
- **PP, HDPE a LDPE:** Najhoršie výsledky z hľadiska úplnosti vykazuje stabilne plast PP. Najnižšiu hodnotu dosiahol pri metóde PLS-DA (47,65 %), pričom ani nelineárny model XGBDT neprekročil hranicu 77 %. Materiál HDPE vykazuje konzistentne vysokú presnosť, avšak jeho nižšia úplnosť indikuje časté zámeny s LDPE z dôvodu ich vysokej chemickej príbuznosti.
- **Vplyv priehľadnosti na presnosť:** Slabšie výsledky v metrike presnosť pri triedach LDPE, PS a transportnom páse sú primárne spôsobené priehľadnosťou niektorých plastových vzoriek. Aj keď je ich úplnosť vysoká, nízka presnosť znamená, že senzory zachytávajú spektrálnu informáciu pozadia cez materiál, čo generuje falošne pozitívne detekcie. Logistická regresia však dokázala tento problém čiastočne eliminovať, nakoľko presnosť pozadia (pas) vzrástla z pôvodných 62,81 % (PLS-DA) na 88,67 %.

Hoci výsledky modelu XGBDT sú z hľadiska štatistických metrík najlepšie, jeho implementácia do priemyselnej praxe na rýchle dopravníkové pásy je problematická. Priemerný čas spracovania jedného riadka (17,5 ms) je limitujúcim faktorom, ktorý neumožňuje spracovanie pri vysokých prepravných rýchlostiach. Ako najvhodnejší kandidát pre reálne nasadenie sa preto javí **logistická regresia**, ktorá predstavuje ideálny balans medzi vysokým F1 score a výpočtovou efektivitou.

Záver

Všimnite si správne písanie slovenských úvodzoviek okolo predchádzajúceho citátu, ktoré sme dosiahli príkazom `\uv`.

V informatických prácach niekedy býva záver kratší ako dve strany, ale stále by to mal byť rozumne dlhý text, v rozsahu aspoň jednej strany. Okrem dosiahnutých cieľov sa zvyknú rozoberať aj otvorené problémy a námety na ďalšiu prácu v oblasti.

Abstrakt, úvod a záver práce obsahujú podobné informácie. Abstrakt je kratší text, ktorý má pomôcť čitateľovi sa rozhodnúť, či vôbec prácu chce čítať. Úvod má umožniť zorientovať sa v práci skôr než ju začne čítať a záver sumarizuje najdôležitejšie veci po tom, ako prácu prečítal, môže sa teda viac zamerať na detaily a využívať pojmy zavedené v práci.

Literatúra

- [1] Ediko sk.
- [2] Chnspec. What is hyperspectral remote sensing? <https://www.chnspec.net/What-is-hyperspectral-remote-sensing.html>, 2024. [Prístup: 10. 4. 2026].
- [3] DataTechNotes. Smoothing example with savitzky-golay filter. <https://www.datatechnotes.com/2022/05/smoothing-example-with-savitzky-golay.html>, 2022. [Prístup: 1. 5. 2026].
- [4] Mario Fordellone, Andrea Bellincontro, and Fabio Mencarelli. Partial least squares discriminant analysis: A dimensionality reduction method to classify hyperspectral data. <https://arxiv.org/pdf/1806.09347>, 2018. [Prístup: 5. 5. 2026].
- [5] GeeksforGeeks. Xgbclassifier in machine learning. <https://www.geeksforgeeks.org/machine-learning/xgbclassifier/>, 2024. Prístup: 16. 5. 2026.
- [6] Google DeepMind. Gemini 3 flash model.
- [7] Cyril Goutte and Eric Gaussier. A probabilistic interpretation of precision, recall and f-score, with implications for evaluation. https://www.researchgate.net/publication/226675412_A_Probabilistic_Interpretation_of_Precision_Recall_and_F-Score_with_Implication_for_Evaluation, 2005. [Prístup: 3. 5. 2026].
- [8] Oswaldo Gressani and Christine Wallisch. Flexible modeling of binary data with the power link family. <https://pmc.ncbi.nlm.nih.gov/articles/PMC11905696/pdf/BIMJ-67-e70050.pdf>, 2025. Biometrical Journal, 67(1), e70050. [Prístup: 18. 5. 2026].
- [9] Alexandre Lussier. Understanding raw data, radiance data, and reflectance data in hyperspectral imaging. <https://resonon.com/blog-raw-radiance-reflectance-hyperspectral-data>, 2024. [Prístup: 10.4.2026].
- [10] School of Physical Education and Brazil Sports – Federal University of Rio de Janeiro, Rio de Janeiro. Understanding logistic regression analysis. <https://pmc.ncbi.nlm.nih.gov/articles/PMC3936971/>, 2014. [Prístup: 5. 5. 2026].
- [11] Plastics For Change. Different types of plastic and their impact. <https://www.plasticsforchange.org/blog/different-types-of-plastic>, 2024. Prístup: 10. 5. 2025.

- [12] Prediktera AB. Dark and white references. <https://help.prediktera.com/breeze/dark-and-white-references>, 2025. [Prístup: 10. 4. 2026].
- [13] Recykal. Plastic waste recycling under three distinct methods. <https://recykal.com/blog/plastic-waste-recycling-under-three-distinct-methods/>, 2024. Prístup: 10. 5. 2025.
- [14] Scholar Developers. Scholar.linear.logisticregression. <https://hexdocs.pm/scholar/Scholar.Linear.LogisticRegression.html>, 2024. [Prístup: 18. 5. 2026].
- [15] Specim, Spectral Imaging Ltd. Illumination sources for hyperspectral imaging. <https://www.specim.com/illumination-sources/>. [Prístup: 20. 5. 2026].
- [16] Specim, Spectral Imaging Ltd. What is hyperspectral imaging? <https://www.specim.com/technology/what-is-hyperspectral-imaging/>. prístup 9. 4. 2026.
- [17] Specim, Spectral Imaging Ltd. Hyperspectral imaging in plastic sorting. <https://www.youtube.com/watch?v=qQ0UcIJOLic>, 2023. Video na YouTube.
- [18] Yi Su, Boyan Li, Jing Li, Bin Guo, and Qi Feng. Hyperspectral remote sensing for soil heavy metal inversion: insights and applications. <https://www.tandfonline.com/doi/full/10.1080/17538947.2025.2520474>, 2025. International Journal of Digital Earth. [Prístup: 8. 5. 2026].

Príloha A: obsah elektronickej prílohy

V elektronickej prílohe priloženej k práci sa nachádza zdrojový kód programu a súbory s výsledkami experimentov. Zdrojový kód je zverejnený aj na stránke <http://mojadresa.com/>.

Ak uznáte za vhodné, môžete tu aj podrobnejšie rozpísať obsah tejto prílohy, prípadne poskytnúť návod na inštaláciu programu. Alternatívou je tieto informácie zahrnúť do samotnej prílohy, alebo ich uviesť na oboch miestach.

Príloha B: Používateľská príručka

V tejto prílohe uvádzame používateľskú príručku k nášmu softvéru. Tu by ďalej pokračoval text príručky. V práci nie je potrebné uvádzať používateľskú príručku, pokiaľ je používanie softvéru intuitívne alebo ak výsledkom práce nie je ucelený softvér určený pre používateľov.

V prílohách môžete uviesť aj ďalšie materiály, ktoré by mohli pôsobiť rušivo v hlavnom texte, ako napríklad rozsiahle tabuľky a podobne. Materiály, ktoré sú príliš dlhé na ich tlač, odovzdajte len v elektronickej prílohe.